HW 6

March 18, 2021

1 IST 387 HW 6

Copyright 2021, Jeffrey Stanton, Jeffrey Saltz, and Jasmina Tacheva

```
[4]: # Enter your name here: Connor Hanan
```

- 1.0.1 Attribution statement: (choose only one and delete the rest)
- [5]: # 1. I did this homework by myself, with help from the book and the professor.

Reminders of things to practice from previous weeks: Descriptive statistics: mean() Install a package: install.packages() ?command: Ask R for help with a command

This module: Data visualization is important because many people can make sense of data more easily when it is presented in graphic form. As a data scientist, you will have to present complex data to decision makers in a form that makes the data interpretable for them. From your experience with Excel and other tools, you know that there are a variety of **common data visualizations** (e.g., pie charts). How many of them can you name?

The most powerful tool for data visualization in R is called **ggplot**. Written by computer/data scientist **Hadley Wickham**, this "**graphics grammar**" tool builds visualizations in layers. This method provides immense flexibility, but takes a bit of practice to master.

1.1 Step 1: Make a copy of the data

A. Copy the **who** dataset from this URL: https://ist387.s3.us-east-2.amazonaws.com/data/who.csv into a new dataframe called **tb**. Your new dataframe, tb, contains a so-called **multivariate time series**: a sequence of measurements on 23 Tuberculosis-related (TB) variables captured repeatedly over time (1980-2013). Familiarize yourself with the nature of the 23 variables by consulting the dataset's codebook which can be found here: https://ist387.s3.us-east-2.amazonaws.com/data/TB_data_dictionary_2021-02-06.csv.

[6]: library(tidyverse)

Attaching packages tidyverse 1.3.0

```
ggplot2 3.3.2 purrr 0.3.4
tibble 3.0.4 dplyr 1.0.2
```

```
tidyr 1.1.2 stringr 1.4.0
      readr
              1.4.0
                          forcats 0.5.0
       Conflicts
     tidyverse_conflicts()
      dplyr::filter() masks stats::filter()
      dplyr::lag()
                      masks stats::lag()
[34]: tb <- read_csv("https://ist387.s3.us-east-2.amazonaws.com/data/who.csv")
       Column specification
     cols(
       .default = col_double(),
       iso2 = col_character()
      Use `spec()` for the full
     column specifications.
 [9]: tb
```

	iso2 <chr></chr>	year <dbl></dbl>	new_sp <dbl></dbl>	$\begin{array}{l} new_sp_m04 \\ < dbl > \end{array}$	new_sp_m514 <dbl></dbl>	new_sp_m014 <dbl></dbl>	new_: <dbl></dbl>
-	AD	1989	NA	NA	NA	NA	NA
	AD	1990	NA	NA	NA	NA	NA
	AD	1991	NA	NA	NA	NA	NA
	AD	1992	NA	NA	NA	NA	NA
	AD	1993	15	NA	NA	NA	NA
	AD	1994	24	NA	NA	NA	NA
	AD	1996	8	NA	NA	0	0
	AD	1997	17	NA	NA	0	0
	AD	1998	1	NA	NA	0	0
	AD	1999	4	NA	NA	0	0
	AD	2000	1	NA	NA	0	0
	AD	2001	3	NA	NA	0	NA
	AD	2002	2	NA	NA	0	0
	AD	2003	7	NA	NA	0	0
	AD	2004	3	NA	NA	0	0
	AD	2005	5	0	0	0	0
	AD	2006	8	0	0	0	1
	AD	2007	2	NA	NA	NA	NA
	AD	2008	3	0	0	0	0
	AE	1980	NA	NA	NA	NA	NA
	AE	1981	NA	NA	NA	NA	NA
	AE	1982	NA	NA	NA	NA	NA
	AE	1983	NA	NA	NA	NA	NA
	AE	1984	NA	NA	NA	NA	NA
	AE	1985	NA	NA	NA	NA	NA
	AE	1986	NA	NA	NA	NA	NA
	AE	1987	NA	NA	NA	NA	NA
	AE	1988	NA	NA	NA	NA	NA
	AE	1989	NA	NA	NA	NA	NA
A spec_tbl_df: 5769×23	AE	1990	NA	NA	NA	NA	NA
	ZM	2008	13211	NA	NA	101	1120
	ZW	1980	NA	NA	NA	NA	NA
	ZW	1981	NA	NA	NA	NA	NA
	ZW	1982	NA	NA	NA	NA	NA
	ZW	1983	NA	NA	NA	NA	NA
	ZW	1984	NA	NA	NA	NA	NA
	ZW	1985	NA	NA	NA	NA	NA
	ZW	1986	NA	NA	NA	NA	NA
	ZW	1987	NA	NA	NA	NA	NA
	ZW	1988	NA	NA	NA	NA	NA
	ZW	1989	NA	NA	NA	NA	NA
	ZW	1990	NA	NA	NA	NA	NA
	ZW	1991	NA	NA	NA	NA	NA
	ZW	1992	NA	NA	NA	NA	NA
	ZW	1993	5331	NA	NA	NA	NA
	ZW	1994	NA	NA	NA	NA	NA
	ZW	1995	8965	NA	NA	NA	NA
	ZW	1996	11965	NA	NA	NA	NA
	ZW	1997	14512	NA	NA	NA	NA
	ZW	1998	14492	NA	NA	NA	NA

B. How often were these measurements taken (in other words, at what frequency were the variables measured)? Put your answer in a comment.

```
[]: #measurements were taken every year for each country
```

1.2 Step 2: Clean-up the NAs with Missing Data Mitigation

A. Create a subset of **tb** containing **only the records for Canada** ("**CA**" in **the iso2 variable**). Save it in a new dataframe called **tbCan**. Make sure this new df has **52 observations** and **23 variables**.

```
[35]: tb %>%
      filter(iso2 == "CA") -> tbcan
      \#doesn't give me the right number of observations because it discards the full \sqcup
       \rightarrow NA rows - reluctantly abandoning dplyr for the subsetting method so I can
       \rightarrow follow the steps
[36]: | tbcan <- tb[tb$iso2 == 'CA',]
[18]: str(tbcan)
     tibble [52 × 23] (S3: tbl_df/tbl/data.frame)
                     : chr [1:52] "CA" "CA" "CA" "CA" ...
      $ year
                     : num [1:52] 1980 1981 1982 1983 1984 ...
      $ new sp
                     : num [1:52] 951 803 812 771 811 791 752 668 682 652 ...
      $ new_sp_m04 : num [1:52] NA ...
      $ new_sp_m514 : num [1:52] NA NA
      $ new sp m014 : num [1:52] 12 8 6 9 3 11 9 9 4 10 ...
      $ new sp m1524: num [1:52] 54 49 52 47 44 42 58 40 43 45 ...
      $ new_sp_m2534: num [1:52] 75 61 66 63 75 70 73 71 73 56 ...
      $ new_sp_m3544: num [1:52] 83 64 69 62 58 59 62 60 62 60 ...
      $ new_sp_m4554: num [1:52] 100 87 90 90 68 77 59 49 52 54 ...
      $ new_sp_m5564: num [1:52] 108 103 91 92 83 81 73 64 68 62 ...
      $ new sp m65 : num [1:52] 186 141 150 123 169 168 147 129 131 122 ...
                     : num [1:52] NA ...
      $ new_sp_mu
      $ new_sp_f04 : num [1:52] NA ...
      $ new_sp_f514 : num [1:52] NA NA
      $ new_sp_f014 : num [1:52] 18 6 7 11 9 5 10 8 6 6 ...
      $ new_sp_f1524: num [1:52] 62 46 51 50 51 30 33 39 38 37 ...
      $ new_sp_f2534: num [1:52] 51 57 57 50 59 56 54 48 56 51 ...
      $ new_sp_f3544: num [1:52] 34 26 30 29 28 19 33 29 27 23 ...
      $ new_sp_f4554: num [1:52] 31 28 25 24 28 28 20 17 16 24 ...
      $ new sp f5564: num [1:52] 33 35 38 35 36 48 26 26 26 21 ...
      $ new_sp_f65 : num [1:52] 104 92 80 86 100 97 95 79 80 81 ...
                     : num [1:52] NA ...
      $ new sp fu
```

A simple method for dealing with small amounts of **missing data** in a numeric variable is to substitute the mean of the variable in place of each missing datum. This expression

locates (and reports to the console) all the missing data elements in the variable measuring the number of positive pulmonary smear tests for male children 0-14 years old:

- [37]: tbcan\$new_sp_m014[is.na(tbcan\$new_sp_m014)]
 - - B. Write a comment describing how that statement works.
- [23]: tbcan #locate all the NA's in the denoted column, then replace it with the mean \rightarrow of the rest of the data (by sorting !is.na)

CA 1981 803 NA NA 8,0000000 49 CA 1982 812 NA NA 6,0000000 52 CA 1983 771 NA NA 3,0000000 47 CA 1984 811 NA NA NA 3,0000000 44 CA 1985 791 NA NA NA 11,0000000 42 CA 1986 752 NA NA 9,0000000 58 CA 1987 668 NA NA 9,0000000 40 CA 1988 682 NA NA 9,0000000 40 CA 1988 682 NA NA NA 10,0000000 45 CA 1989 652 NA NA NA 10,0000000 45 CA 1999 549 NA NA 3,0000000 35 CA 1991 543 NA NA 3,0000000 37 CA 1992 506 NA NA NA 6,0000000 37 CA 1993 488 NA NA NA 6,0000000 42 CA 1993 488 NA NA NA 2,0000000 42 CA 1994 483 NA NA NA 2,0000000 42 CA 1995 436 NA NA NA 3,0000000 28 CA 1996 430 NA NA NA 3,0000000 28 CA 1996 430 NA NA NA 0,0000000 28 CA 1996 455 NA NA NA 0,0000000 28 CA 1996 455 NA NA NA 0,0000000 21 CA 1998 438 NA NA NA 0,0000000 23 CA 2001 458 NA NA NA 0,0000000 24 CA 2001 458 NA NA NA 0,0000000 24 CA 2001 458 NA NA NA 0,0000000 25 CA 2003 332 NA NA NA 0,0000000 25 CA 2004 488 NA NA NA 0,0000000 26 CA 2007 463 NA NA NA 0,0000000 25 CA 2004 488 NA NA 0,0000000 26 CA 2007 463 NA NA NA 0,0000000 26 CA 2007 463 NA NA NA 0,0000000 25 CA 2004 488 NA NA NA 0,0000000 26 CA 2007 483 NA NA NA 0,0000000 34 CA 2008 488 NA NA NA 0,00576923 NA		CA	1980	951	NA	NA	12.0000000	54
CA 1984 811 NA NA 3.0000000 47 CA 1985 791 NA NA NA 3.0000000 42 CA 1985 791 NA NA NA 11.0000000 42 CA 1986 752 NA NA NA 9.0000000 40 CA 1988 682 NA NA 9.0000000 43 CA 1989 652 NA NA 10.0000000 43 CA 1990 549 NA NA 3.0000000 35 CA 1991 543 NA NA 7.0000000 42 CA 1992 506 NA NA NA 2.0000000 42 CA 1993 488 NA NA 8.0000000 37 CA 1994 483 NA NA 8.0000000 42 CA 1995 436 NA NA 1.0000000 42 CA 1995 436 NA NA 1.0000000 42 CA 1995 437 NA NA 1.0000000 42 CA 1995 NA NA NA 1.0000000 33 CA 1996 430 NA NA 1.0000000 33 CA 1996 430 NA NA 1.0000000 28 CA 1997 473 NA NA 1.0000000 28 CA 1997 473 NA NA 1.0000000 28 CA 1999 455 NA NA NA 0.0000000 33 CA 1999 455 NA NA NA 0.0000000 33 CA 1999 455 NA NA NA 0.0000000 33 CA 1999 455 NA NA NA 0.0000000 25 CA 2000 492 NA NA NA 6.0000000 24 CA 2001 458 NA NA NA 0.0000000 25 CA 2003 332 NA NA NA 1.0000000 25 CA 2004 438 NA NA 1.0000000 31 CA 2006 407 1 1 2.0000000 37 CA 2006 407 1 1 2.0000000 37 CA 2006 407 1 1 2.0000000 31 CA 2006 407 NA NA 0.0576923 NA		CA	1981	803	NA	NA	8.0000000	49
CA 1985 791 NA NA 11.0000000 44 CA 1986 752 NA NA 9.0000000 58 CA 1987 668 NA NA 9.0000000 40 CA 1988 682 NA NA 10.0000000 43 CA 1989 652 NA NA 10.0000000 45 CA 1989 652 NA NA 10.0000000 35 CA 1999 549 NA NA 10.0000000 37 CA 1991 543 NA NA 7.0000000 37 CA 1992 506 NA NA NA 6.0000000 42 CA 1993 488 NA NA 2.0000000 42 CA 1994 483 NA NA 2.0000000 28 CA 1995 436 NA NA 1.0000000 28 CA 1995 436 NA NA 1.0000000 28 CA 1996 430 NA NA 0.0000000 28 CA 1997 473 NA NA 0.0000000 28 CA 1998 438 NA NA 0.0000000 28 CA 1999 455 NA NA NA 0.0000000 33 CA 1999 455 NA NA NA 0.0000000 33 CA 1999 455 NA NA NA 0.0000000 33 CA 2000 492 NA NA NA 0.0000000 34 CA 2001 458 NA NA 0.0000000 33 CA 2000 492 NA NA NA 0.0000000 34 CA 2001 458 NA NA 0.0000000 35 CA 2002 408 NA NA 0.0000000 25 CA 2003 332 NA NA 0.0000000 25 CA 2004 438 NA NA 0.0000000 37 CA 2006 407 I I 2.0000000 39 NA NA NA NA NA NA 0.5576923 NA	CA CA CA	CA	1982	812	NA	NA	6.0000000	52
CA 1986 752 NA NA 9,0000000 42 CA 1986 752 NA NA NA 9,0000000 40 CA 1987 668 NA NA 9,0000000 40 CA 1989 652 NA NA NA 4,0000000 43 CA 1989 652 NA NA NA 10,0000000 45 CA 1990 549 NA NA 3,0000000 37 CA 1991 543 NA NA 6,0000000 37 CA 1992 506 NA NA NA 6,0000000 42 CA 1993 488 NA NA 8,0000000 33 CA 1994 483 NA NA 8,0000000 22 CA 1995 436 NA NA 1,0000000 22 CA 1995 436 NA NA 1,0000000 28 CA 1996 430 NA NA 1,0000000 28 CA 1997 473 NA NA 1,0000000 28 CA 1998 438 NA NA 0,0000000 23 CA 1998 438 NA NA 1,0000000 21 CA 1998 455 NA NA NA 4,0000000 23 CA 1999 455 NA NA NA 6,0000000 23 CA 2000 492 NA NA 5,0000000 23 CA 2001 458 NA NA 6,0000000 24 CA 2001 458 NA NA 6,0000000 25 CA 2004 492 NA NA 6,0000000 25 CA 2004 493 NA NA 6,0000000 25 CA 2004 493 NA NA 6,0000000 25 CA 2004 438 NA NA 0,0000000 37 CA 2005 433 NA NA 1,0000000 25 CA 2006 407 1 1 1 2,0000000 31 CA 2006 488 0 2 2,0000000 31 CA 2006 488 0 2 2,0000000 31 CA 2007 463 4 1 5,000000 31 CA 2008 488 0 2 2,0000000		CA	1983	771	NA	NA	9.0000000	47
CA 1986 752 NA NA 9,0000000 58 CA 1987 668 NA NA NA 9,0000000 40 CA 1988 682 NA NA NA 4,000000 43 CA 1989 652 NA NA NA 10,000000 45 CA 1990 549 NA NA 3,0000000 35 CA 1991 543 NA NA 7,000000 37 CA 1992 506 NA NA RA 6,000000 42 CA 1993 488 NA NA NA 8,000000 33 CA 1994 483 NA NA NA 2,000000 42 CA 1995 436 NA NA 8,000000 33 CA 1996 430 NA NA 1,0000000 28 CA 1996 430 NA NA 3,0000000 28 CA 1997 473 NA NA 3,0000000 28 CA 1998 438 NA NA NA 3,0000000 28 CA 1999 455 NA NA NA 0,0000000 21 CA 1999 455 NA NA NA 0,0000000 23 CA 2000 492 NA NA 0,0000000 31 CA 2001 458 NA NA 0,0000000 24 CA 2002 408 NA NA 0,0000000 24 CA 2003 332 NA NA 0,0000000 24 CA 2004 438 NA NA 0,0000000 25 CA 2003 332 NA NA 1,0000000 25 CA 2004 438 NA NA 0,0000000 25 CA 2004 438 NA NA 0,0000000 25 CA 2004 438 NA NA 0,0000000 37 CA 2006 407 1 1 2,0000000 35 CA 2006 407 1 1 2,0000000 31 CA 2006 407 NA NA NA NA 0,5576923 NA		CA	1984	811	NA	NA	3.0000000	44
CA		CA	1985	791	NA	NA	11.0000000	42
CA 1989 652 NA NA 10.000000 43 CA 1989 652 NA NA NA 10.000000 45 CA 1990 549 NA NA NA 3.0000000 35 CA 1991 543 NA NA NA 7.0000000 37 CA 1992 506 NA NA NA 6.0000000 42 CA 1993 488 NA NA NA 2.0000000 33 CA 1995 436 NA NA NA 2.0000000 42 CA 1995 436 NA NA NA 1.0000000 28 CA 1996 430 NA NA NA 3.0000000 28 CA 1996 430 NA NA NA 0.0000000 21 CA 1998 438 NA NA NA 0.0000000 21 CA 1998 438 NA NA NA 0.0000000 23 CA 1999 455 NA NA NA 0.0000000 23 CA 1999 455 NA NA NA 0.0000000 23 CA 2000 492 NA NA NA 6.0000000 24 CA 2001 458 NA NA 6.0000000 24 CA 2001 458 NA NA 1.0000000 25 CA 2003 332 NA NA NA 6.0000000 25 CA 2004 438 NA NA 1.0000000 25 CA 2004 438 NA NA 1.0000000 25 CA 2004 438 NA NA 1.0000000 36 CA 2004 438 NA NA 0.0000000 36 CA 2006 407 1 1 2.0000000 37 CA 2006 433 NA NA NA 2.0000000 37 CA 2006 433 NA NA NA 0.0000000 37 CA 2006 407 1 1 2.0000000 31 CA 2006 488 0 2 2.0000000 31 CA 2006 488 NA NA NA 0.0576923 NA		CA	1986	752	NA	NA	9.0000000	58
CA		CA	1987	668	NA	NA	9.0000000	40
CA 1990 549 NA NA 3.0000000 35 CA 1991 543 NA NA NA 7.0000000 42 CA 1993 488 NA NA 8.0000000 42 CA 1994 483 NA NA NA 2.0000000 42 CA 1996 436 NA NA NA 1.0000000 28 CA 1996 430 NA NA NA 1.0000000 28 CA 1997 473 NA NA NA 0.0000000 21 CA 1999 455 NA NA NA 0.0000000 23 CA 1999 455 NA NA NA 0.0000000 23 CA 1999 455 NA NA NA 0.0000000 23 CA 2000 492 NA NA NA 5.0000000 24 CA 2000 492 NA NA NA 6.0000000 24 CA 2001 458 NA NA NA 6.0000000 24 CA 2002 408 NA NA NA 0.0000000 25 CA 2003 332 NA NA NA 0.0000000 25 CA 2004 428 NA NA NA 0.0000000 25 CA 2005 433 NA NA 1.0000000 25 CA 2006 407 1 1 2.0000000 31 CA 2006 407 1 1 2.0000000 31 CA 2007 463 4 1 1 5.0000000 31 CA 2008 488 0 2 2 2.0000000 34 NA NA NA NA NA NA NA 0.5576923 NA		CA	1988	682	NA	NA	4.0000000	43
CA 1991 543 NA NA 6.000000 37 CA 1992 506 NA NA 6.000000 42 CA 1993 488 NA NA 8.0000000 33 CA 1994 483 NA NA NA 2.000000 42 CA 1995 436 NA NA NA 1.0000000 28 CA 1996 430 NA NA NA 3.000000 28 CA 1997 473 NA NA NA 4.0000000 21 CA 1997 473 NA NA NA 4.0000000 21 CA 1999 455 NA NA NA 4.0000000 23 CA 1999 455 NA NA NA 6.0000000 23 CA 2000 492 NA NA NA 6.0000000 24 CA 2001 458 NA NA 6.0000000 24 CA 2001 458 NA NA 6.0000000 25 CA 2002 408 NA NA 0.0000000 25 CA 2003 332 NA NA NA 0.0000000 25 CA 2003 332 NA NA NA 0.0000000 25 CA 2005 433 NA NA 3.000000 25 CA 2006 407 1 1 2.0000000 31 CA 2008 488 NA NA NA 3.000000 37 CA 2006 407 1 1 2.0000000 31 CA 2008 488 NA NA NA 0.5576923 NA		CA	1989	652	NA	NA	10.0000000	45
CA 1992 506 NA NA 8.0000000 42 CA 1993 488 NA NA 8.0000000 42 CA 1995 436 NA NA 8.0000000 42 CA 1995 436 NA NA NA 1.0000000 28 CA 1996 430 NA NA NA 3.0000000 21 CA 1998 438 NA NA NA 0.0000000 21 CA 1998 438 NA NA NA 0.0000000 21 CA 1999 455 NA NA NA 0.0000000 23 CA 1999 455 NA NA NA 0.0000000 24 CA 2000 492 NA NA NA 5.0000000 24 CA 2001 458 NA NA NA 6.0000000 24 CA 2001 458 NA NA NA 0.0000000 25 CA 2001 458 NA NA NA 0.0000000 25 CA 2003 332 NA NA NA 0.0000000 25 CA 2004 488 NA NA 1.0000000 25 CA 2005 433 NA NA 3.0000000 25 CA 2006 407 1 1 1 2.0000000 37 CA 2006 407 1 1 1 2.0000000 31 CA 2008 488 0 2 2.0000000 31 CA 2008 488 0 2 2.0000000 31 CA 2008 488 0 2 2.0000000 31 NA NA NA NA NA NA NA 0.5576923 NA O.5576923 NA O.5576923 NA		CA	1990	549	NA	NA	3.0000000	35
CA 1993 488 NA NA 8.0000000 33 CA 1994 483 NA NA NA 2.0000000 42 CA 1995 436 NA NA NA 1.0000000 28 CA 1996 430 NA NA NA 0.0000000 28 CA 1997 473 NA NA NA 0.0000000 21 CA 1998 438 NA NA NA 4.0000000 23 CA 1999 455 NA NA NA 0.0000000 23 CA 2000 492 NA NA NA 5.0000000 24 CA 2001 458 NA NA NA 6.0000000 24 CA 2001 458 NA NA NA 6.0000000 25 CA 2003 332 NA NA NA 1.0000000 25 CA 2004 408 NA NA 0.0000000 25 CA 2003 332 NA NA NA 1.0000000 25 CA 2003 332 NA NA NA 2.0000000 25 CA 2003 332 NA NA NA 2.0000000 37 CA 2005 433 NA NA 3.0000000 37 CA 2006 407 I I 2.0000000 34 CA 2007 463 4 I 5.0000000 31 CA 2008 488 0 2 2 2.0000000 39 NA NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA NA 0.5576923 NA		CA	1991	543	NA	NA	7.0000000	37
CA 1994 483 NA NA 2.0000000 42 CA 1995 436 NA NA NA 1.0000000 28 CA 1996 430 NA NA NA 3.0000000 28 CA 1997 473 NA NA NA 0.0000000 21 CA 1998 438 NA NA NA 0.0000000 21 CA 1999 455 NA NA NA 0.0000000 23 CA 2000 492 NA NA 5.0000000 24 CA 2001 458 NA NA 0.0000000 24 CA 2002 408 NA NA 0.0000000 25 CA 2003 332 NA NA 0.0000000 25 CA 2004 438 NA NA 1.0000000 25 CA 2005 433 NA NA 2.0000000 25 CA 2006 407 1 1 2.0000000 37 CA 2006 407 1 1 2.0000000 31 CA 2007 463 4 1 5.0000000 31 CA 2008 488 0 2 2.0000000 31 CA 2008 488 0 2 2.0000000 39 NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA 0.5576923 NA 0.5576923 NA		CA	1992	506	NA	NA	6.0000000	42
CA 1994 483 NA NA 2.0000000 42 CA 1995 436 NA NA NA 1.0000000 28 CA 1996 430 NA NA NA 3.0000000 28 CA 1997 473 NA NA NA 0.0000000 21 CA 1998 438 NA NA NA 0.0000000 21 CA 1999 455 NA NA NA 0.0000000 23 CA 2000 492 NA NA 5.0000000 24 CA 2001 458 NA NA 0.0000000 24 CA 2002 408 NA NA 0.0000000 25 CA 2003 332 NA NA 0.0000000 25 CA 2004 438 NA NA 1.0000000 25 CA 2005 433 NA NA 2.0000000 25 CA 2006 407 1 1 2.0000000 37 CA 2006 407 1 1 2.0000000 31 CA 2007 463 4 1 5.0000000 31 CA 2008 488 0 2 2.0000000 31 CA 2008 488 0 2 2.0000000 39 NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA 0.5576923 NA 0.5576923 NA			1993	488	NA	NA	8.0000000	33
CA 1995 436 NA NA 1.0000000 28 CA 1996 430 NA NA NA 3.0000000 21 CA 1997 473 NA NA NA 0.0000000 21 CA 1999 455 NA NA NA 0.0000000 33 CA 2000 492 NA NA NA 5.0000000 24 CA 2000 492 NA NA NA 6.0000000 24 CA 2001 458 NA NA NA 6.0000000 25 CA 2003 332 NA NA NA 1.0000000 25 CA 2003 332 NA NA NA 1.0000000 25 CA 2004 438 NA NA 1.0000000 25 CA 2006 407 1 1 2.0000000 37 CA 2006 407 1 1 2.0000000 31 CA 2006 407 1 1 2.0000000 31 CA 2008 488 0 2 2.0000000 39 NA NA NA NA NA NA NA 0.5576923 NA O.5576923 NA			1994			NA	2.0000000	
CA 1996 430 NA NA NA 0.0000000 28 CA 1997 473 NA NA NA 0.0000000 21 CA 1998 438 NA NA NA 0.0000000 23 CA 1999 455 NA NA NA 0.0000000 23 CA 2000 492 NA NA NA 0.0000000 24 CA 2001 458 NA NA 0.0000000 24 CA 2002 408 NA NA 0.0000000 25 CA 2003 332 NA NA 1.0000000 25 CA 2003 332 NA NA 1.0000000 25 CA 2005 433 NA NA 2.0000000 37 CA 2006 407 1 1 2.0000000 34 CA 2006 407 1 1 2.0000000 31 CA 2008 488 0 2 2.0000000 31 CA 2008 488 0 2 2.0000000 39 NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA NA 0.5576923 NA 0.5576923 NA			1995				1.0000000	28
CA 1997 473 NA NA 0.0000000 21 CA 1998 438 NA NA NA 4.0000000 33 CA 1999 455 NA NA NA 5.0000000 23 CA 2000 492 NA NA 5.0000000 34 CA 2000 492 NA NA 5.0000000 24 CA 2001 458 NA NA NA 6.0000000 25 CA 2002 408 NA NA 1.0000000 25 CA 2003 332 NA NA 1.0000000 25 CA 2004 438 NA NA 2.0000000 25 CA 2005 433 NA NA 2.0000000 37 CA 2006 407 1 1 2.0000000 34 CA 2007 463 4 1 5.0000000 31 CA 2008 488 0 2 2.0000000 39 NA NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA NA 0.5576923 NA								
CA 1998 438 NA NA A 4.0000000 33 CA 1999 455 NA NA NA 0.0000000 23 CA 2000 492 NA NA NA 5.0000000 34 CA 2001 458 NA NA 6.0000000 24 CA 2001 458 NA NA 6.0000000 24 CA 2001 458 NA NA 6.0000000 25 CA 2003 332 NA NA NA 1.0000000 26 CA 2003 332 NA NA NA 1.0000000 26 CA 2005 433 NA NA NA 3.0000000 37 CA 2006 407 1 1 1 2.0000000 37 CA 2006 407 1 1 1 2.0000000 31 CA 2008 488 0 2 2.0000000 31 CA 2008 488 0 2 2.0000000 39 NA							0.0000000	
CA 1999 455 NA NA 0.0000000 23 CA 2000 492 NA NA S.0000000 34 CA 2001 458 NA NA 6.0000000 24 CA 2002 408 NA NA 0.0000000 25 CA 2003 332 NA NA 1.0000000 26 CA 2003 438 NA NA 2.0000000 25 CA 2004 438 NA NA 3.0000000 37 CA 2005 433 NA NA NA 3.000000 37 CA 2007 463 4 1 5.000000 31 CA 2007 463 4 1 5.000000 31 CA 2008 488 0 2 2 2.000000 39 NA NA NA NA NA NA NA 0.5576923 NA 0.5576923 NA O.5576923 NA								
CA 2000 492 NA NA S.0000000 34 CA 2001 458 NA NA NA 6.0000000 24 CA 2002 408 NA NA NA 0.0000000 25 CA 2003 332 NA NA 1.0000000 26 CA 2003 332 NA NA 1.0000000 25 CA 2004 438 NA NA 2.0000000 25 CA 2005 433 NA NA 3.000000 37 CA 2006 407 1 1 2.0000000 34 CA 2008 488 0 2 2.0000000 39 NA NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA NA 0.5576923 NA 0.5576923 NA 0.5576923 NA 0.5576923 NA 0.5576923 NA 0.5576923 NA 0.5576923 NA 0.5576923 NA 0.5576923 NA								
CA 2001 458 NA NA 0.0000000 24 CA 2002 408 NA NA 0.0000000 25 CA 2003 332 NA NA 1.0000000 26 CA 2004 438 NA NA 2.0000000 25 CA 2005 433 NA NA 3.0000000 37 CA 2006 407 1 1 2.0000000 34 CA 2007 463 4 1 5.0000000 39 NA NA NA NA NA NA 0.5576923 NA								
CA 2002 408 NA NA 0.0000000 25 CA 2003 332 NA NA NA 1.0000000 26 CA 2004 438 NA NA 2.0000000 25 CA 2005 433 NA NA 3.0000000 37 CA 2006 407 1 1 2.0000000 34 CA 2007 463 4 1 5.000000 31 CA 2008 488 0 2 2.0000000 39 NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA								
CA 2003 332 NA NA 1.0000000 26 CA 2004 438 NA NA 2.0000000 25 CA 2005 433 NA NA NA 3.0000000 37 CA 2006 407 1 1 1 2.0000000 34 CA 2007 463 4 1 5.0000000 39 NA NA NA NA NA NA 0.5576923 NA								
Cable: 52 × 23 CA								
CA 2005 433 NA NA 3.0000000 37 CA 2006 407 1 1 1 2.0000000 34 CA 2007 463 4 1 5.0000000 31 CA 2008 488 0 2 2.0000000 39 NA NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA NA NA NA NA NA NA NA NA O.5576923 NA								
CA 2006 407 1 1 2.0000000 34 CA 2007 463 4 1 5.000000 31 CA 2008 488 0 2 2.0000000 39 NA NA NA NA 0.5576923 NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA 0.5576923 NA NA<	tibble: 52×23							
CA 2007 463 4 1 5.0000000 31 CA 2008 488 0 2 2.0000000 39 NA NA NA NA NA 0.5576923 NA NA NA NA NA NA 0.5576923 NA NA NA NA NA 0.5576923 NA NA NA NA NA 0.5576923 NA NA NA NA NA 0.5576923 NA NA NA NA NA 0.5576923 NA NA NA NA NA 0.5576923 NA NA NA NA NA 0.5576923 NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA <								
NA NA<			2007	463	4	1	5.0000000	31
NA NA<		CA	2008	488	0	2	2.0000000	39
NA NA NA NA NA NA NA NA NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA NA NA NA NA <td></td> <td>NA</td> <td>NA</td> <td>NA</td> <td>NA</td> <td>NA</td> <td>0.5576923</td> <td>NA</td>		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA <td></td> <td>NA</td> <td>NA</td> <td>NA</td> <td>NA</td> <td>NA</td> <td>0.5576923</td> <td>NA</td>		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA N		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA NA NA NA NA NA NA NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA NA NA NA NA NA NA NA NA NA NA NA NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA 0.5576923 NA		NA	NA	NA	NA	NA	0.5576923	NA
NA NA NA NA NA 0.5576923 NA 0.5576923 NA		NA	NA			NA	0.5576923	
NA NA NA NA NA 0.5576923 NA NA NA NA NA NA 0.5576923 NA		NA	NA	NA	ŊΑ	NA	0.5576923	NA
		NA	NA	NA		NA	0.5576923	NA
$egin{array}{cccccccccccccccccccccccccccccccccccc$		NA	NA	NA	NA	NA	0.5576923	NA
		NA	NA	NA	NA	NA	0.5576923	NA

A 1

iso2

CA

<chr>

year

1980

<dbl>

 new_sp

<dbl>

NA

<dbl>

951

 $new_sp_m04 \quad new_sp_m514 \quad new_sp_m014 \quad new_sp_m152$

<dbl>

NA

<dbl>

12.0000000

<dbl>

54

C. Write one more statement to report missing data for the number of positive pulmonary smear tests for **female** children 0-14 years old, and a statement for the number of positive pulmonary smear tests for the **male and female citizens 65 years of age and older**, respectively.

```
[38]: tbcan$new_sp_f014[is.na(tbcan$new_sp_f014)] tbcan$new_sp_f65[is.na(tbcan$new_sp_f65)] tbcan$new_sp_m65[is.na(tbcan$new_sp_m65)]
```

- [27]: tbcan

	CA	1901	000	NA	NA	8.0000000	49
CA CA CA CA	1982	812	NA	NA	6.0000000	52	
	CA	1983	771	NA	NA	9.0000000	47
	CA	1984	811	NA	NA	3.0000000	44
	CA	1985	791	NA	NA	11.0000000	42
	CA	1986	752	NA	NA	9.0000000	58
	CA	1987	668	NA	NA	9.0000000	40
	CA	1988	682	NA	NA	4.0000000	43
	CA	1989	652	NA	NA	10.0000000	45
	CA	1990	549	NA	NA	3.0000000	35
	CA	1991	543	NA	NA	7.0000000	37
	\overline{CA}	1992	506	NA	NA	6.0000000	42
	CA	1993	488	NA	NA	8.0000000	33
	\overline{CA}	1994	483	NA	NA	2.0000000	42
	CA	1995	436	NA	NA	1.0000000	28
	CA	1996	430	NA	NA	3.0000000	28
	CA	1997	473	NA	NA	0.0000000	21
	CA	1998	438	NA	NA	4.0000000	33
	CA	1999	455	NA	NA	0.0000000	23
	CA	2000	492	NA	NA	5.0000000	34
	CA	2001	458	NA	NA	6.0000000	24
	CA	2002	408	NA	NA	0.0000000	25
	CA	2003	332	NA	NA	1.0000000	26
	CA	2004	438	NA	NA	2.0000000	$\frac{25}{25}$
tibble: 52×23	CA	2005	433	NA	NA	3.0000000	37
	CA	2006	407	1	1	2.0000000	34
	CA	2007	463	4	1	5.0000000	31
	CA	2008	488	0	2	2.0000000	39
	NA	NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA
NA		NA	NA	NA	NA	0.5576923	NA
		NA	NA	NA	NA	0.5576923	NA
		NA	NA	NA NA	NA	0.5576923	NA
		NA	NA	NA NA	NA	0.5576923	NA
		NA NA	NA NA	NA NA	NA NA	0.5576923	NA NA
				NA NA	NA NA		
		NA NA	NA NA			0.5576923	NA NA
		NA NA	NA NA	NA NA	NA NA	0.5576923	NA NA
		NA NA	NA NA	NA	NA	0.5576923	NA NA
		NA	NA	NA	NA	0.5576923	NA
	NA	NA	NA	NA	NA	0.5576923	NA

 $new_sp_m04 \quad new_sp_m514 \quad new_sp_m014 \quad new_sp_m152$

 $<\!\!\mathrm{dbl}\!\!>$

12.0000000

8.0000000

<dbl>

54

49

<dbl>

NA

NA

A t

iso2

CA

 CA

<chr>

year

1980

1981

<dbl>

 new_sp

<dbl>

NA

NA

<dbl>

951

803

There is an R package called **imputeTS** specifically designed to repair missing values in time series data. We will use this instead of mean substitution. The **na_interpolation()** function in this package takes advantage of a unique characteristic of time series data: **neighboring points in time can be used to "guess" about a missing value in between**.

D. Install the **imputeTS** package and use **na_interpolation()** on the four variables whose missing values you reported on in B & C. Don't forget that you need to save the results back to the **tbCan** dataframe.

```
[29]: #install.packages('imputeTS')
library(imputeTS)
```

```
Registered S3 method overwritten by 'quantmod':
method from
as.zoo.data.frame zoo
```

E. Rerun the code from B & C above to check that all missing data have been fixed.

```
[46]: tbcan$new_sp_m014[is.na(tbcan$new_sp_f014)]
tbcan$new_sp_f014[is.na(tbcan$new_sp_f014)]
tbcan$new_sp_f65[is.na(tbcan$new_sp_f65)]
tbcan$new_sp_m65[is.na(tbcan$new_sp_m65)]
```

1.3 Step 3: Use ggplot to explore the distribution of each variable

Don't forget to install and library the ggplot2 package. Then: F. Create a histogram for new_sp_m014. Be sure to add a title and briefly describe what the histogram means in a comment.

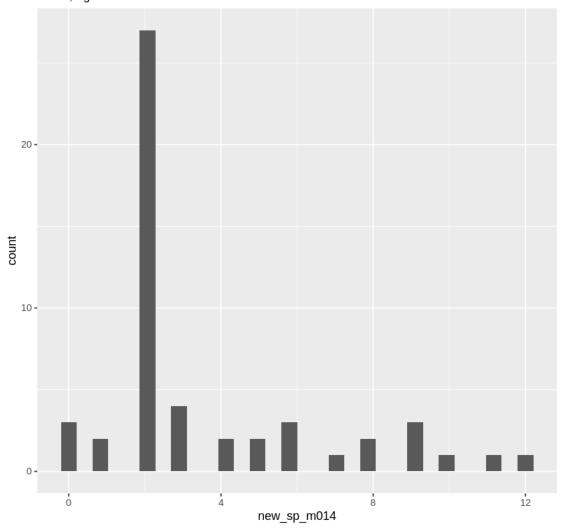
```
[47]: library(tidyverse)
```

```
[49]: tbcan %>%
ggplot() +
geom_histogram(aes(new_sp_m014)) +
ggtitle("Count of Postive Pulmonary Smear Tests", subtitle = "Males, Ages 0-14")

#this histogram shows the Count of Postive Pulmonary Smear Tests in Males, Ages
→ 0-14
```

[`]stat_bin()` using `bins = 30`. Pick better value with `binwidth`.

Count of Postive Pulmonary Smear Tests Males, Ages 0-14



G. Create histograms of each of the other three variables with ggplot(). Which parameter do you need to adjust to make the other histograms look right?

```
[51]: tbcan %>%
    ggplot() +
    geom_histogram(aes(new_sp_f014)) +
    ggtitle("Count of Postive Pulmonary Smear Tests", subtitle = "Females, Ages_\( \to \to \to -14\)

    tbcan %>%
    ggplot() +
    geom_histogram(aes(new_sp_m65)) +
    ggtitle("Count of Postive Pulmonary Smear Tests", subtitle = "Males, Ages 65+")
```

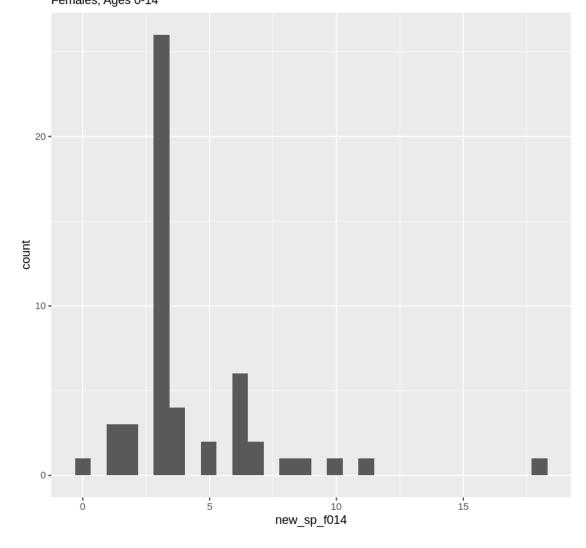
```
tbcan %>%
ggplot() +
geom_histogram(aes(new_sp_f65)) +
ggtitle("Count of Postive Pulmonary Smear Tests", subtitle = "Females, Ages_\( \infty 65+")

#you have to change the x aesthetic each time, as well as the title
```

`stat_bin()` using `bins = 30`. Pick better value with `binwidth`.

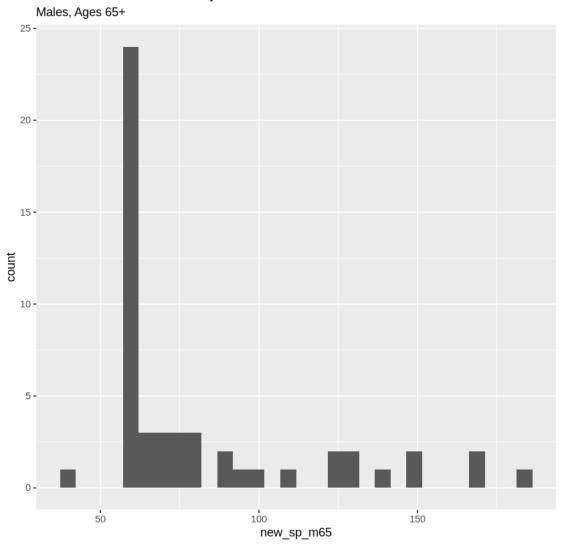
`stat_bin()` using `bins = 30`. Pick better value with `binwidth`.

Count of Postive Pulmonary Smear Tests Females, Ages 0-14

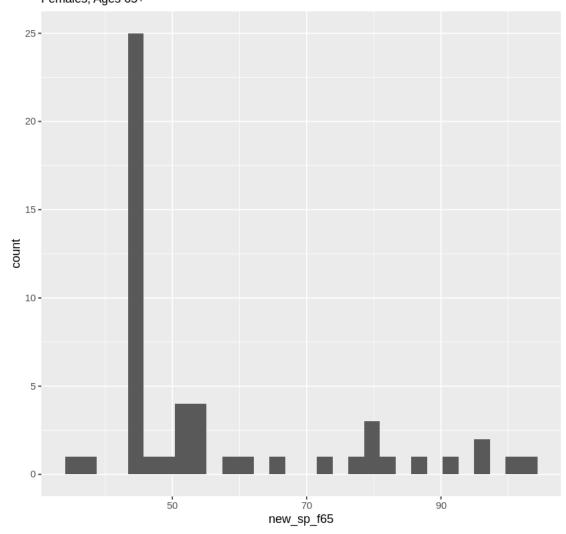


`stat_bin()` using `bins = 30`. Pick better value with `binwidth`.

Count of Postive Pulmonary Smear Tests



Count of Postive Pulmonary Smear Tests Females, Ages 65+



1.4 Step 4: Explore how the data changes over time

H. These data were collected in a period of several decades. You can thus observe changes over time with the help of a line chart. Create a line chart, with year on the X-axis and new_sp_m014 on the Y-axis.

[58]: library(scales)

Attaching package: 'scales'

The following object is masked from 'package:purrr':

discard

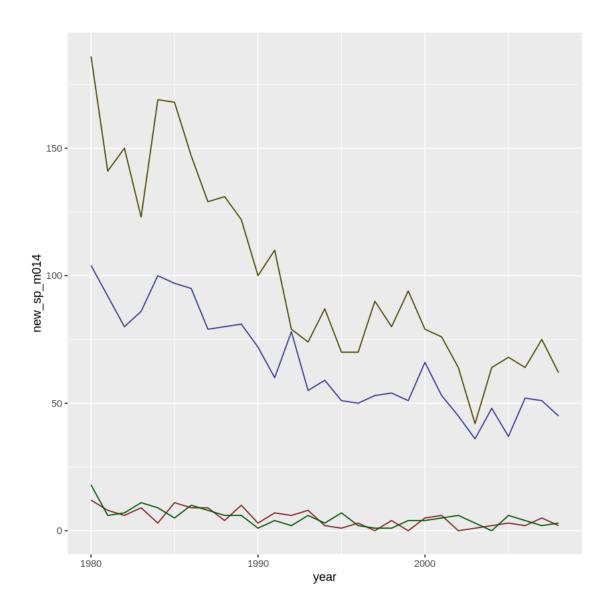
```
col_factor

[61]: tbcan %>%
    ggplot()+
    geom_line(aes(year,new_sp_m014), color = muted('red'))+
    geom_line(aes(year,new_sp_f014), color = muted('green'))+
    geom_line(aes(year,new_sp_m65), color = muted('yellow'))+
    geom_line(aes(year,new_sp_m65), color = muted('blue'))

Warning message:
    "Removed 23 row(s) containing missing values (geom_path)."
    Warning message:
    "Removed 23 row(s) containing missing values (geom_path)."
    Warning message:
    "Removed 23 row(s) containing missing values (geom_path)."
    Warning message:
    "Removed 23 row(s) containing missing values (geom_path)."
    Warning message:
```

The following object is masked from 'package:readr':

"Removed 23 row(s) containing missing values (geom_path)."



I. Next, create similar graphs for each of the other three variables. Change the **color** of the line plots (any color you want).

[]: #see above

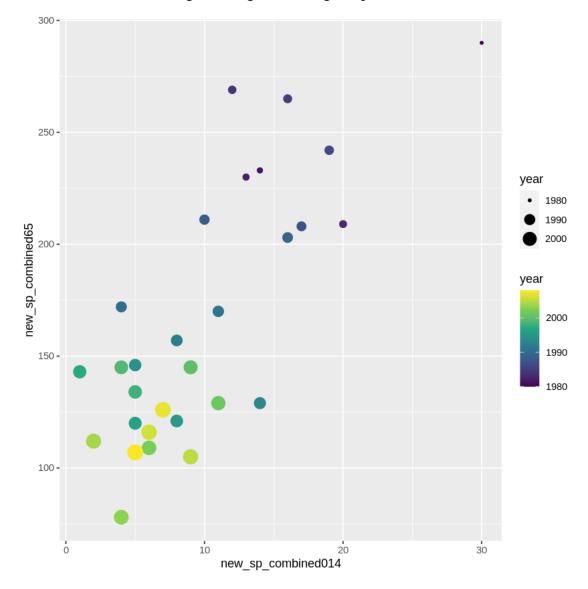
J. Using vector math, create a new variable by combining the numbers from new_sp_m014 and new_sp_f014. Save the resulting vector as a new variable in the tbCan df called new_sp_combined014. This new variable represents the number of positive pulmonary smear tests for male AND female children between the ages of 0 and 14 years of age. Do the same for SP tests among citizens 65 years of age and older and save the resulting vector in the tbCan variable called new_sp_combined65.

K. Finally, create a **scatter plot**, showing **new_sp_combined014** on the x axis, **new_sp_combined65** on the y axis, and having the **color and size** of the point represent **year**.

```
[67]: tbcan %>%
ggplot()+
geom_point(aes(new_sp_combined014,new_sp_combined65, color = year, size = year))+
scale_color_viridis_c()
```

Warning message:

"Removed 23 rows containing missing values (geom_point)."



L. Interpret this visualization – what insight does it provide?

[68]: #there are fewer positive tests in the combined014 group than that of the →combined65 - you can tell purely by the scales of the axes